Hanoi Land Law Assistant

Báo cáo đồ án liên ngành — nguyên mẫu học thuật

Sinh viên/nhóm, lớp, giảng viên: điền thông tin trước khi nộp.

1. Bài toán và mục tiêu

Văn bản pháp luật phân tán, có thay đổi theo thời điểm và thường khó đọc với người không chuyên. Đồ án xây dựng web chatbot tiếng Việt hỗ trợ tìm căn cứ về bồi thường, hỗ trợ và tái định cư ở Hà Nội. Vành đai 4 là tình huống minh họa. Mục tiêu là minh họa một hệ thống AI có truy xuất và nguồn dẫn, không xác định quyền lợi pháp lý của từng hộ.

2. Đóng góp liên ngành

Lĩnh vực	Công việc
Kỹ thuật dữ liệu	Thu thập nguồn chính thức, parse HTML/PDF, chia đoạn theo cấu trúc, metadata và phiên bản
Trí tuệ nhân tạo	Embedding E5, hybrid retrieval, LangGraph, tổng hợp có chứng cứ và kiểm tra trích dẫn
Kỹ thuật phần mềm	React/TypeScript, FastAPI, phiên hội thoại, SSE, Docker, kiểm thử và triển khai
Kiến thức miền	Phân biệt quy định chung, hồ sơ dự án, thời điểm áp dụng và dữ kiện cá nhân còn thiếu

3. Kiến trúc

```mermaid
flowchart LR
    D[Nguồn chính thức] --> P[Parse và chia đoạn ngoại tuyến]
    P --> E[E5 embedding trên Colab]
    E --> DB[(Supabase PostgreSQL pgvector)]
    W[React web] --> API[FastAPI SSE]
    API --> G[LangGraph và công cụ chỉ đọc]
    G --> DB
    G --> N[NVIDIA Nemotron 3 Super]
    N --> V[Kiểm tra nguồn và trích dẫn]
    V --> W
```

Backend và frontend chạy riêng trên Render và Cloudflare Pages. Supabase lưu corpus và hội thoại. E5 xử lý truy vấn trên CPU backend; không chạy mô hình sinh hoặc OCR trên Render. Không sử dụng công nghệ embedding khác trong cùng index.

4. Dữ liệu và retrieval

Corpus snapshot đang sử dụng có 69 tài liệu và 7.610 vector 384 chiều; danh mục nguồn nằm tại `data/sources.json`. Văn bản được lưu nguồn công bố, checksum, ngày kiểm tra và locator điều/khoản/trang. OCR và dữ liệu chưa đạt kiểm tra không được dùng để bù số lượng. Tin tiến độ dự án chỉ bổ sung bối cảnh.

Hybrid retrieval kết hợp tìm từ khóa PostgreSQL và vector bằng Reciprocal Rank Fusion. Kết quả truy xuất là ứng viên; không tự chứng minh điều khoản áp dụng cho hồ sơ cá nhân. Nguồn dẫn cho phép mở đoạn và văn bản gốc.

5. Agent và giao diện

Workflow xác định vấn đề, gọi công cụ truy xuất/mở điều khoản/quan hệ văn bản, tổng hợp rồi kiểm tra trước khi phát đáp án qua SSE. Có giới hạn thực thi để tránh vòng lặp. Trace hiển thị sự kiện và công cụ thực tế, không hiển thị suy nghĩ nội bộ.

Người dùng nhập câu hỏi, chọn ngày/dự án nếu cần, đọc đáp án và mở nguồn/trace. Hệ thống có thể hỏi lại hoặc trả lời có giới hạn. Baseline được giữ để minh họa nhưng không giả định agentic luôn tốt hơn.

6. Phương pháp đánh giá

Dùng lại 20 câu smoke có rubric và nguồn tham chiếu tại `data/evaluation/smoke.jsonl`. Chạy agentic qua API cloud, lưu câu trả lời, model, corpus, fingerprint, độ trễ và kết quả đối chiếu ID/đoạn nguồn. Tôn trọng giới hạn API công khai; checkpoint khi gián đoạn. Câu tiếp nối chạy sau câu trước trong cùng phiên khi bộ dữ liệu yêu cầu.

Kết quả mới được lưu riêng tại `reports/submission/evaluation.json`; bảng dễ đọc tại `reports/submission/results.md`. Kiểm tra máy chỉ xác nhận giao thức và nguồn tồn tại; chấm nội dung cần đọc câu trả lời và đối chiếu rubric. Những câu chưa rà soát phải ghi `awaiting_review`, không tính là đạt. Không lấy số liệu cũ, CLI hoặc model khác để thay thế.

7. Kết quả và bằng chứng

Checkpoint hiện tại đã chạy và rà soát 16/20 câu trên cloud: 12 pass, 2 partial, 2 fail theo rubric kỹ thuật; bốn câu còn lại chưa chạy do giới hạn lượt/ngày của API công khai. Tất cả trích dẫn xuất hiện trong 16 ca đều khớp đoạn nguồn qua endpoint tài liệu. Các ca không có trích dẫn không được tính như bằng chứng hỗ trợ kết luận. Không tính tỷ lệ chất lượng toàn hệ thống từ checkpoint này. Xem bảng kết quả hiện hành trong `reports/submission/`. Báo cáo backend/frontend được lưu riêng với ngày chạy. Nếu đánh giá cloud bị gián đoạn, số câu đã chạy và nguyên nhân phải được nêu rõ. Không đưa tỷ lệ chất lượng hoặc kết luận nghiệm thu khi chưa có đủ dữ liệu chấm.

Các receipt trước đây ở `reports/live-demo.json`, `reports/live-ui.json` và `reports/postgres-restore.json` là bằng chứng lịch sử, không tự động là kết quả của mã nguồn hiện tại.

8. Hạn chế

- Chưa được thẩm định pháp lý độc lập; dữ liệu là snapshot, có nguồn và quan hệ còn thiếu.
- Retrieval và giải tham chiếu có thể bỏ sót; một số câu hỏi bị trả lời giới hạn dù có căn cứ trong corpus.
- Nguồn đúng không tự bảo đảm mọi kết luận trong đáp án đúng.
- Hosting miễn phí có cold start; provider có thể timeout/quota. Không cam kết SLA.
- Không tính tiền bồi thường, xác định quy hoạch từng thửa hay xử lý hồ sơ cá nhân nhạy cảm.
- 20 ca có chọn lọc không đại diện mọi câu hỏi thực tế; không tuyên bố cải thiện so với baseline nếu chưa đo cùng cấu hình.

9. Hướng phát triển

Chỉ sau học phần: mở rộng đánh giá, thẩm định miền độc lập, cải thiện retrieval và giải tham chiếu, cập nhật nguồn có kiểm duyệt. Đây không phải điều kiện hoàn thành bản nộp.

10. Tài liệu tham khảo và tái lập

Nguồn pháp lý: `data/sources.json`, trang nguồn trong ứng dụng và metadata corpus. Công nghệ: FastAPI, LangGraph, PostgreSQL/pgvector, multilingual-e5-small, NVIDIA hosted Nemotron, React/Vite. Cài đặt theo README và phiên bản khóa trong repository. Không đưa khóa API hoặc token phiên vào báo cáo.

Kết quả 20 ca trên API cloud

Trạng thái: **partial**. Đã chạy 16/20. Chưa tự động chấm đúng pháp lý.

Ca	Trạng thái API	Giây	Trích dẫn khớp nguồn	Review nội dung
S01	answered	23.69	True	pass
S02	clarification_needed	8.19	True	pass
S03	answered	11.63	True	pass
S04	answered	15.07	True	pass
S05	answered	20.14	True	pass
S06	answered	12.75	True	partial
S07	answered	17.32	True	pass
S08	answered	14.14	True	pass
S09	clarification_needed	9.42	True	pass
S10	clarification_needed	12.55	True	pass
S11	clarification_needed	8.22	True	pass
S12	insufficient_evidence	36.85	True	fail
S13	answered	9.79	True	pass

S14	insufficient_evidence	24.1	True	fail
S15	insufficient_evidence	6.61	True	pass
S16	insufficient_evidence	32.85	True	partial

Phạm vi: API công khai, một người dùng, có thể gồm cold start. Không phải p95/SLA; không ghép báo cáo cấu hình khác. Câu tiếp nối S14 dùng câu trả lời thật của lượt mở đầu cùng phiên; không chèn lịch sử giả.

Ghi chú rà soát kỹ thuật (không phải thẩm định pháp lý độc lập)

- S01: Nêu QĐ56 hết hiệu lực và QĐ40 thay thế từ 02/04/2026; đối chiếu Điều 2 trong đoạn nguồn.
- S02: Không áp QĐ40 trước ngày hiệu lực, hỏi thêm ngày quyết định/phương án thay vì tính quyền lợi.
- S03: Phân biệt bãi bỏ Điều 2 với bãi bỏ toàn bộ QĐ38; dẫn Điều 2 QĐ10.
- S04: Đáp án bám quy định chuyển tiếp về phương án đã phê duyệt và xử lý chi trả chậm trong Điều 31.
- S05: Nêu Chủ tịch UBND cấp xã thực hiện thẩm quyền; trích Điều 5, không khái quát mọi thẩm quyền.
- S06: Nêu điều kiện thay thế giấy chứng nhận và giới hạn khoản 1, nhưng danh sách chỉ a/b có thể bị hiểu là đầy đủ; cần nêu đây là ví dụ hoặc liệt kê đủ.
- S07: Các chi phí tháo dỡ/di chuyển/lắp đặt và thiệt hại máy móc bám Điều 104.
- S08: Nêu đủ sáu nhóm hỗ trợ và điều kiện dẫn chiếu trong Điều 108.
- S09: Hỏi giấy tờ, loại đất, thời điểm, nhu cầu di chuyển; không hứa suất tái định cư.
- S10: Không suy quyền lợi/thửa đất từ tổng quan Vành đai 4; hỏi hồ sơ và ranh thu hồi.
- S11: Không khẳng định quyền lợi từ thông tin dự án sông Hồng; cần dữ kiện và hồ sơ. Đáp án còn chung chung.
- S12: Không suy đoán thu hồi từng hộ nhưng không phân biệt được nhiệm vụ quy hoạch với phê duyệt đồ án; hỏi lại tài liệu đã có thay vì trả lời quy tắc chung.
- S13: Câu không dấu vẫn nêu đúng mốc thay thế QĐ56/QĐ40 và nguồn Điều 2.
- S14: Cùng phiên đã hỏi QĐ40, nhưng lượt tiếp nối không giải tham chiếu văn bản đó; cần nêu rõ số văn bản khi demo.
- S15: Từ chối câu y tế ngoài phạm vi, không đưa phác đồ.
- S16: Không xác nhận số tiền 50 tỷ, nhưng diễn đạt không có trong bất kỳ văn bản nào quá rộng so với corpus snapshot; nên nói chưa tìm thấy căn cứ trong nguồn đã kiểm tra.

Trở ngại: ValueError: Public daily/provider limit: resume checkpoint later